- 크롤링(Crawling)
 - 조직적 / 자동화된 방법으로 데이터를 탐색 / 수집 하는 것
 - 데이터 수집 절차
 - 원하는 URL에 request를 보내고 결과를 받는다
 - 받은 결과물(HTML / JSON / XML)을 파싱(Parsing)한다
 - 필요한 정보만 추출한다
 - 파이썬에서 크롤링을 하기 위해 필요한 라이브러리
 - 데이터 통신: requests / urllib / urllib2
 - 파싱 : bs4 (BeautifulSoup)

■ 크롤링(Crawling)

requests

import requests

● URL 호출 후 응답코드 확인

```
result = requests.get('http://ggoreb.com/http') result.status_code
```

200

● 응답결과 확인

result.text

● Encoding 처리

result.encoding = 'utf-8' result.text

```
"<html lang='ko'>₩n<head>₩n <meta charset='utf-8' >₩n</head>₩n<body>₩n<h3>₩n <a href='#'>奇니비</a>₩n </h3>₩n</body>₩n</html>"
```

- 크롤링(Crawling)
 - 공통으로 사용할 함수 작성 (인코딩 처리 / 응답결과 text)

```
def get_html(url):
   html = ''
   res = requests.get(url)
   if res.status_code == 200:
      res.encoding = 'utf-8'
      html = res.text
   return html
```

■ requests 모듈

● 기본 사용

```
import requests
res = requests.get('http://ggoreb.com/python/request.jsp')
print(res.status_code)
print(res.text)
```

```
200
method : GET<br>
query string<br>
<br><br><br>>
header<br>
kev : accept. value : */*<br>
key: Accept-Encoding, value: gzip, deflate<br/>br>
kev : connection. value : close<br>
kev : host, value : ggoreb.com<br>
key: HOSTING_CONTINENT_CODE, value: AS<br>
key: HOSTING_COUNTRY_CODE, value: KR<br>
kev : HOSTING_WHITE_IP, value : false<br/>
key : user-agent, value : python-requests/2.22.0<br>
key: X-Forwarded-Proto, value: http<br/>
kev : X-SERVER_PORT, value : 80<br>
key: X-SERVER_PROTOCOL, value: HTTP/1.1<br>
kev : X-SIMPLEXI. value : 14.138.9.145<br>
kev : content-length, value : 0<br>
```

■ requests 모듈

● 파라미터 사용

import requests

```
param = { 'page': 1, 'search': '검색어' }
res = requests.get('http://ggoreb.com/python/request.jsp', params=param)
print(res.text)
method : GET<br>
query string<br>
key : search, value : 검색어<br>
kev : page, value : 1<br>
<br><br><br>>
header<br>
kev : accept, value : */*<br>
key : Accept-Encoding, value : gzip, deflate<br/>
kev : connection. value : close<br>
kev : host. value : ggoreb.com<br>
key: HOSTING_CONTINENT_CODE. value: AS<br>
kev: HOSTING_COUNTRY_CODE, value: KR<br>
key: HOSTING_WHITE_IP. value: false<br/>
key : user-agent, value : python-requests/2.22.0<br>
key: X-Forwarded-Proto, value: http<br/>
key: X-SERVER_PORT, value: 80<br>
key: X-SERVER_PROTOCOL, value: HTTP/1.1<br>
key: X-SIMPLEXI, value: 14.138.9.145<br>
key : content-length, value : 0<br>
```

■ requests 모듈

● 헤더 사용

```
import requests
header = { 'user-agent': 'android', 'accept-language': 'en' }
res = requests.get('http://ggoreb.com/python/request.jsp', headers=header)
print(res.text)
```

```
method: GET<br>
auerv string<br>
<br><br><br>>
header<br>
key : accept, value : */*<br>
key : Accept-Encoding, value : gzip, deflate<br/>
kev : accept-language, value : en<br/>
kev : connection. value : close<br>
kev : host, value : ggoreb.com<br>
key: HOSTING_CONTINENT_CODE, value: AS<br>
key: HOSTING_COUNTRY_CODE, value: KR<br>
kev : HOSTING_WHITE_IP, value : false<br>
key : user-agent, value : android<br>
key: X-Forwarded-Proto, value: http<br>
kev : X-SERVER_PORT, value : 80<br>
key: X-SERVER_PROTOCOL, value: HTTP/1.1<br>
key: X-SIMPLEXI, value: 14.138.9.145<br>
kev : content-length, value : 0<br>
```

- Parsing (반복문 / find / indexing)
 - 응답결과 확인

import requests
result = get_html('http://ggoreb.com/python/html/data1.html')
result

'<!DOCTYPE html>\m<body>\m\m<h2>Basic HTML Table</h2>\m\m\<table style =\midth:100%\mathrm{\table} \table \table \table \table style =\midth:100%\mathrm{\table} \table \t

Basic HTML Table			
Firstname	Lastname	Age	
Jill	Smith	50	
Eve	Jackson	94	
John	Doe	80	

```
<h2>Basic HTML Table</h2>
••• ▼ == $0
  ▼
  ▶ ...
  ▼
    Jill
    Smith
    50
    Eve
    Jackson
    94
   John
    Doe
    80
   </body>
```

- Parsing (반복문 / find / indexing)
 - 원하는 위치를 찾은 후 문자열 잘라내기

```
s_idx = 0
e_idx = 0
while True:
    s_idx = result.find('', e_idx)
    if s_idx == -1:
        break
    e_idx = result.find('', s_idx)
    print(result[s_idx + 4 : e_idx])
```

```
Jill
Smith
50
Eve
Jackson
94
John
Doe
80
```

- Parsing (반복문 / find / indexing)
 - 응답결과 확인

import requests
result = get_html('http://ggoreb.com/python/html/data2.html')
result

'<!DOCTYPE html>\m<html>\m<head>\m<style>\m\table {\m\n font-family: arial.s border-collapse: collapse;\mathfrak{\pi} width: 100%;\mathfrak{\pi} \mathfrak{\pi} \mathfrak{\pi ans-serif;₩n border: 1px solid #dddddd;\mathbb{\pm}n text-align: left;\mathbb{\pm}n padding: 8px;\mathbb{\pm}n\mathbb{\pm}n\mathbb{\pm}nt r:nth-child(even) {\psin background-color: #dddddd;\psin}\psin</style>\psin</head>\psin
b odv>\m\m<h2>HTML Table</h2>\m\m\m\n \m\n \m\n </ra> Country\\mathrm{\tr>\\mathrm{\tr>\\mathrm{\tr>\\mathrm{\tr}} Alfreds Futterk >Contact\m iste₩n Maria Anders₩n Germany₩n ₩n Centro comercial Moctezuma\\mathbb{H}n Francisco Chang\\mathbb{H}n Me xico\\mathrice \\mathrice xico\\mathrice \\mathrice Helen Bennett\\mathred{W}n UK\\mathred{W}n \\mathred{W}n \\mathred{W}n \\mathreal{Laughing} Ba cchus Winecellars\\mathbb{\tan} \td>Yoshi Tannamuri\\mathbb{\tan} \td>Canada\\mathbb{\tan} ₩n ₩n Magazzini Alimentari Riuniti₩n Giovanni Ro velli\mm ltalv\mm \munclerr>\munclerr>\munclerr>\munclerr>\munclerr>\munclerrr>\

- Parsing (반복문 / find / indexing)
 - 응답결과 확인

HTML Table

Company	Contact	Country
Alfreds Futterkiste	Maria Anders	Germany
Centro comercial Moctezuma	Francisco Chang	Mexico
Ernst Handel	Roland Mendel	Austria
Island Trading	Helen Bennett	UK
Laughing Bacchus Winecellars	Yoshi Tannamuri	Canada
Magazzini Alimentari Riuniti	Giovanni Rovelli	Italy

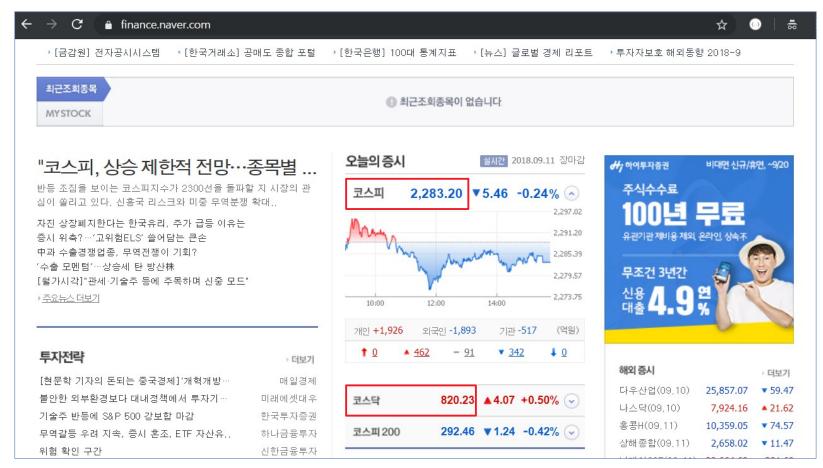
```
... ▼ == $0
  ▼
   ▼
     Company
     Contact
     Country
    ▼
     Alfreds Futterkiste
     Maria Anders
     Germany
    ▶ ...
   ▶ ...
   ▶ ...
   ▶ ...
   ▶ ...
```

- Parsing (반복문 / find / indexing)
 - 원하는 위치를 찾은 후 문자열 잘라내기

```
s_idx = 0
e_idx = 0
while True:
    s_idx = result.find('', e_idx)
    if s_idx == -1:
        break
    e_idx = result.find('', s_idx)
    print(result[s_idx + 4 : e_idx])
```

```
Alfreds Futterkiste
Maria Anders
Germany
Centro comercial Moctezuma
Francisco Chang
Mexico
Ernst Handel
Roland Mendel
Austria
Island Trading
Helen Bennett
UK
Laughing Bacchus Winecellars
Yoshi Tannamuri
Canada
Magazzini Alimentari Riuniti
Giovanni Rovelli
Italy
```

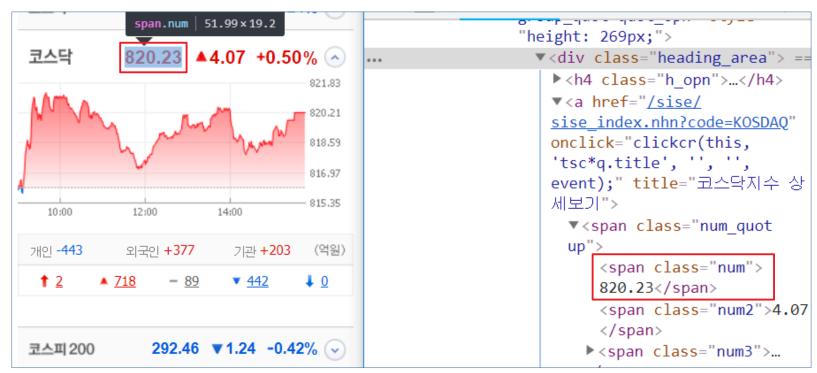
● 네이버 주식 정보 코스피 / 코스닥 지수 추출



● 네이버 주식 정보 코스피 / 코스닥 지수 추출



● 네이버 주식 정보 코스피 / 코스닥 지수 추출



- Parsing (BeautifulSoup)
 - 응답결과 확인

```
import requests
result = get_html('https://finance.naver.com')
result
```

'<html lang="ko">₩n <head> ₩n <title>�������</title> ₩n <meta h ttp-equiv="Content-Type" content="text/html; charset=utf-8" /> \mathbb{\pm} \cdot <meta ht tp-equiv="Content-Script-Type" content="text/javascript" /> \mathbb{\pm} <meta httpequiv="Content-Style-Type" content="text/css" /> \mathbb{\pm}n < meta property="og:tit Ie" content="���� ���" /> ₩n <meta property="og:image" content="h ttps://ssl.pstatic.net/static/m/stock/im/2016/08/og_stock-200.png"/>\\m\ < meta property="og:url" content="https://finance.naver.com" /> \mathbb{m} < meta pro ��g, �ơ♠, ����, ���å� ���ġ�� ����" /> ₩n <meta pro perty="og:type" content="article" /> \mathbb{m} < meta property="og:article:thumbna ilUrl" content="" /> ₩n <meta property="og:article:author" content="�� �����" /> ₩n <meta property="og:article:author:url" content="htt p://FINANCE.NAVER.COM" /> \mathbb{m} < | ink rel="stylesheet" type="text/css" href ="/css/finance_header.css?20191212151800" /> \mathbb{#n < link rel="stylesheet" type e="text/css" href="/css/finance.css?20191212151800" /> \mathref="style" sheet" type="text/css" href="/css/newstock3.css?20191212151800" /> \mathred{\pi}n <scr ipt type="text/javascript" src="/js/jindo.min.ns.1.5.3.euckr.js?20191212151

● get_html 함수 수정

```
def get_html(url):
   html = ''
   res = requests.get(url)
   if res.status_code == 200:
      res.encoding = None
      html = res.text
   return html
```

'<html lang="ko">\m <head> \m <title>네이버 금융</title> \m <meta http-equiv="Content-Type" content="text/html; charset=utf-8" /> \m <meta http-equiv="Content-Script-Type" content="text/javascript" /> \m <meta http-equiv="Content-Style-Type" content="text/css" /> \m <meta property="og:title" content="dolh 금융" /> \m <meta property="og:image" content="https://ssl.pstatic.net/static/m/stock/im/2016/08/og_stock-200.png" /> \m <meta property="og:description" content="https://finance.naver.com" /> \m <meta property="og:description" content="국내 해외 증시 지수, 시장지표, 펀드, 뉴스, 증권사 리서치등 제공" /> \m <meta property="og:type" content="article" /> \m <meta property="og:article:thumbnailUrl" content="" /> \m <meta property="og:article:author:url" content="Http://FINANCE.NAVER.COM" /> \m link rel="stylesheet" type="text/css" href="/css/newstock3 css?20191212151800" /> \m

- Parsing (BeautifulSoup) select (select_one)
 - CSS 선택자를 이용하여 요소 찾기

```
from bs4 import BeautifulSoup
soup = BeautifulSoup(result, 'html.parser')
tags = soup.select('span.num')
num = tags[0].getText()
print(num)
num = tags[1].getText()
print(num)
```

```
2,203.71
647.62
```

● 반복문을 이용한 문자열 추출

```
for tag in tags:
    print(tag.getText())
```

```
2,203.71
647.62
294.87
```

- Parsing (BeautifulSoup) find (find_all)
 - 태그명을 사용하여 원하는 요소 찾기

```
import requests
from bs4 import BeautifulSoup
res = requests.get('http://ggoreb.com/python/html/example.html')
soup = BeautifulSoup(res.text, 'html.parser')
print(soup.find('div'))
print(soup.find('div').getText())
```

```
<!DOCTYPE html>
<div>
                                                                                                                    <html>
\langle p \rangle_a \langle p \rangle
                                                                                                                          <head>
>b
                                                                                                                          </head>
\langle p \rangle c \langle p \rangle
                                                                                                                         <body>
</div>
                                                                                                                                <vib>
                                                                                                                                      a
                                                                                                                                      \langle p \rangle c \langle p \rangle
а
                                                                                                                               </div>
b
С
                                                                                                                                      <q\>b<q>
                                                                                                                                      p e / p 
                                                                                                                                      \langle q \rangle f \langle p \rangle
                                                                                                                                </div>
                                                                                                                               <div id="ex id">
```

```
<title>Page title</title>
         <div class="ex_class">
              \langle q \rangle q \langle p \rangle
              h
              \langle p \rangle i \langle /p \rangle
         </div>
         <h1>This is a heading</h1>
         This is a paragraph.
         This is another paragraph.
    </body>
</html>
```

- Parsing (BeautifulSoup) find (find_all)
 - 태그명을 사용하여 원하는 요소 찾기

```
import requests
from bs4 import BeautifulSoup
res = requests.get('http://ggoreb.com/python/html/example.html')
soup = BeautifulSoup(res.text, 'html.parser')
print(soup.find_all('div'))
```

```
\lceil \langle div \rangle \rceil
                                                                                                             <html>
a
                                                                                                                  <head>
                                                                                                                        <title>Page title</title>
\langle p \rangle b \langle p \rangle
                                                                                                                  </head>
\langle p \rangle c \langle p \rangle
                                                                                                                  <body>
                                                                                                                        <vib>>
</div>. <div class="ex class">
                                                                                                                              \langle q \rangle d \langle p \rangle
                                                                                                                             \langle p \rangle e \langle p \rangle
                                                                                                                             \langle p \rangle c \langle p \rangle
                                                                                                                        </div>
\langle p \rangle f \langle p \rangle
                                                                                                                        <div class="ex class">
</div>. <div id="ex_id">
                                                                                                                             <q\>b<q>
\langle p \rangle g \langle p \rangle
                                                                                                                             p e / p 
                                                                                                                             f
<a\>h</a>
                                                                                                                        </div>
\langle p \rangle i \langle p \rangle
                                                                                                                        <div id="ex id">
</div>1
                                                                                                                             g
                                                                                                                             h
                                                                                                                             \langle p \rangle i \langle p \rangle
                                                                                                                        </div>
                                                                                                                        <h1>This is a heading</h1>
                                                                                                                        This is a paragraph.
                                                                                                                        This is another paragraph.
                                                                                                                  </body>
                                                                                                             </html>
```

- Parsing (BeautifulSoup) find (find_all)
 - id 속성을 사용하여 원하는 요소 찾기

```
soup.find('div', {'id': 'ex_id'})
```

```
soup.find(attrs={'id': 'ex_id'})
```

```
<div id="ex_id">
  g
  h
  i
  i
  </div>
```

● class 속성을 사용하여 원하는 요소 찾기

```
soup.find(attrs={'class': 'ex_class'})
```

```
<div class="ex_class">
d
<</p>
<f>>
f
</div>
```

```
<!DOCTYPE html>
<html>
     <head>
          <title>Page title</title>
     </head>
     <body>
          <div>
               \langle p \rangle b \langle /p \rangle
               \langle p \rangle c \langle /p \rangle
          </div>
          <div class="ex class">
               d
               e
               f
         </div>
          <div id="ex id">
               \langle p \rangle g \langle p \rangle
               h
               \langle p \rangle i \langle p \rangle
          </div>
          \frac{h1}{his} is a heading \frac{h1}{his}
          This is a paragraph.
          This is another paragraph.
     </body>
</html>
```

- Parsing (BeautifulSoup) find (find_all)
 - 그외 여러가지 속성을 사용하여 원하는 요소 찾기

```
import requests
from bs4 import BeautifulSoup
res = requests.get('http://ggoreb.com/python/html/example2.html')
soup = BeautifulSoup(res.text, 'html.parser')
```

- 개수 제한

```
print(soup.find_all('p', limit=2))
                                              <html>
                                                 <head>
                                                    <title>Page title</title>
[a. b]
                                                 </head>
                                                 <body>
                                                    <v i b>
                                                       a
- Text 매칭
                                                       <a>>b
                                                       c
print(soup.find_all(string='a'))
                                                    </div>
                                                    <hr>>
                                                    <h1>This is a heading 1</h1>
['a']
                                                    This is a paragraph.
                                                    This is another paragraph.
                                                    <h1 class='sub'>This is a heading 2</h1>
- Text 매칭 (정규식)
                                                 </body>
                                              </html>
import re
print(soup.find_all(string=re.compile('This.*')))
```

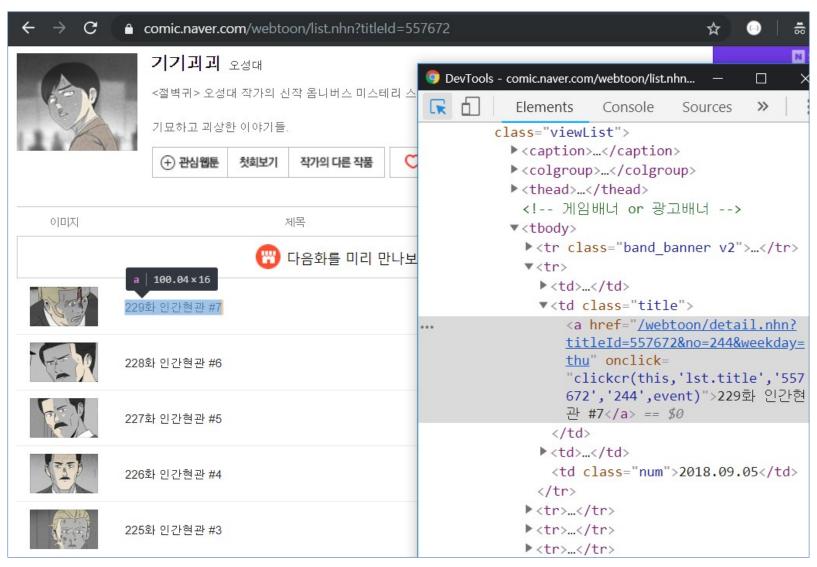
```
['This is a heading 1', 'This is a paragraph.', 'This is another paragraph.', 'This is a heading 2']
```

- Parsing (BeautifulSoup) find (find_all)
 - 그외 여러가지 속성을 사용하여 원하는 요소 찾기
 - 찾은 요소의 지정 속성 확인

```
soup.find('h1', {'class': 'sub'})['class']
```

```
['sub']
                                                  <html>
                                                    <head>
                                                       <title>Page title</title>
- 찾은 요소의 모든 속성 확인
                                                    </head>
                                                    <body>
soup.find('p', {'data-role': 'click'}).attrs
                                                        <v i b>
                                                           a
                                                           {'data-role': 'click'}
                                                           c
                                                        </div>
                                                        <hr>>
- 찾은 요소의 다음 요소 확인
                                                       <h1>This is a heading 1</h1>
                                                       This is a paragraph.
                                                       This is another paragraph.
soup.find(attrs={'class': 'desc'}).find_next()
                                                       <h1 class='sub'>This is a heading 2</h1>
                                                    </body>
\langle p \rangle b \langle p \rangle
                                                 </html>
```

● 네이버 웹툰 제목 추출



225화 인간현관 #3 224화 인간현관 #2 223화 인간현관 #1 222화 성장산 #3 221화 성장산 #2 220화 성장산 #1

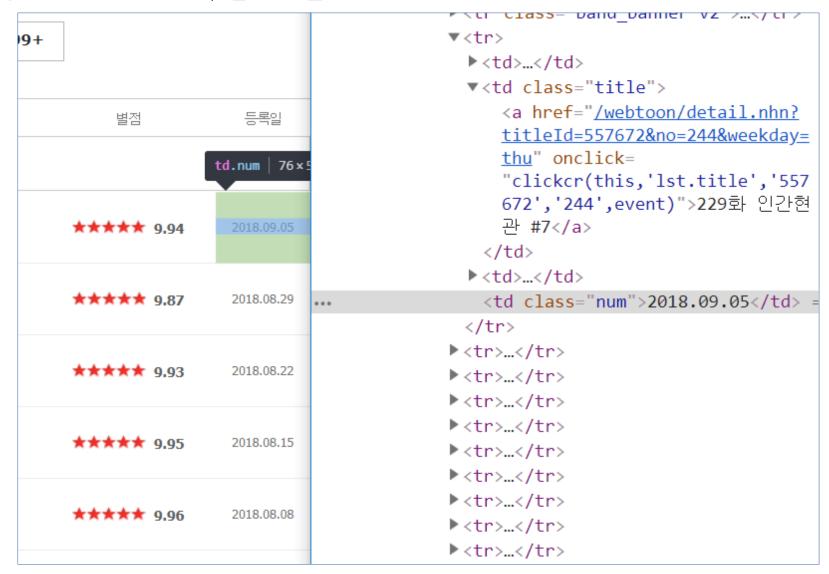
● 네이버 웹툰 제목 추출

```
result = get_html('https://comic.naver.com/webtoon/list.nhn?titleId=557672')
parse = BeautifulSoup(result, 'html.parser')

titles = parse.select('td.title > a')
for title in titles:
    print(title.getText().replace('\m', ''))

229화 인간현관 #7
228화 인간현관 #6
227화 인간현관 #5
226화 인간현관 #4
```

● 네이버 웹툰 제목 / 날짜 추출



● 네이버 웹툰 제목 / 날짜 추출

```
result = get_html('https://comic.naver.com/webtoon/list.nhn?titleId=557672')
table = parse.select_one('table.viewList')
trs = table.select('tr')
for tr in trs:
    title = tr.select_one('td.title > a')
    if title:
        print(title.get('href')) # print(title['href'])
        print(title.getText().replace('\m', ''), end=' // ')
    num = tr.select_one('.num')
    if num:
        print(num.getText())
```

```
/webtoon/detail.nhn?titleId=557672&no=244&weekday=thu 229화 인간현관 #7 // 2018.09.05
/webtoon/detail.nhn?titleId=557672&no=243&weekday=thu 228화 인간현관 #6 // 2018.08.29
/webtoon/detail.nhn?titleId=557672&no=242&weekday=thu 227화 인간현관 #5 // 2018.08.22
/webtoon/detail.nhn?titleId=557672&no=241&weekday=thu 226화 인간현관 #4 // 2018.08.15
/webtoon/detail.nhn?titleId=557672&no=240&weekday=thu 225화 인간현관 #3 // 2018.08.08
```

- Parsing (BeautifulSoup)
 - XML 문서 정보 추출 1
 - 데이터 로드 함수 작성

```
def get_xml(url):
    xml = ''
    resp = requests.get(url)
    if resp.status_code == 200:
        resp.encoding = None
        xml = resp.text
    return xml
```

- 데이터 파싱

- XML 문서 정보 추출 2
 - 데이터 파싱

```
from bs4 import BeautifulSoup
result = get_xml('http://ggoreb.com/python/xml/data2.xml')
parse = BeautifulSoup(result, 'xml')
persons = parse.findAll('person')
for person in persons:
    number = person.find('number')
                                                              ▼<persons>
    name = person.find('name')
                                                                ▼ <person>
    print(number.text)
                                                                   <number>1</number>
    print(name.text)
                                                                   <name>kim</name>
                                                                  </person>
                                                                ▼ <person>
kim
                                                                   <number>2</number>
                                                                   <name>lee</name>
lee
                                                                  </person>
                                                                ▼<person>
park
                                                                   <number>3</number>
                                                                   <name>park</name>
                                                                  </person>
                                                                </persons>
```

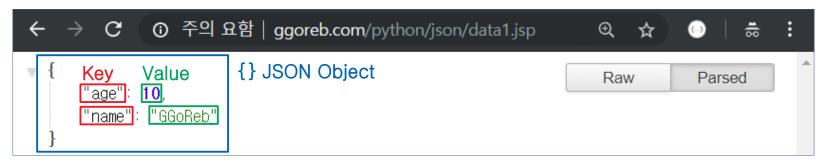
● XML 문서 정보 추출 - 3

Data [number=3, name=park]

- 데이터 파싱 / 클래스 활용

```
from bs4 import BeautifulSoup
class Data:
    number = 0
    name = ''
    def __str__(self):
        return 'Data [number=' + str(self.number) + ', name=' + self.name + ']'
data_list = []
                                                                  ▼<persons>
result = get_xml('http://ggoreb.com/python/xml/data2.xml')
                                                                    ▼ <person>
parse = BeautifulSoup(result, 'xml')
                                                                        <number>1</number>
persons = parse.findAll('person')
                                                                        <name>kim</name>
for person in persons:
                                                                      </person>
    number = person.find('number')
                                                                    ▼ <person>
    name = person.find('name')
                                                                        <number>2</number>
    d = Data()
                                                                        <name>lee</name>
    d.number = number.text
                                                                      </person>
    d.name = name.text
                                                                    ▼ <person>
    data list.append(d)
                                                                        <number>3</number>
                                                                        <name>park</name>
for data in data_list:
                                                                      </person>
    print (data)
                                                                    </persons>
Data [number=1, name=kim]
Data [number=2, name=lee]
```

- Parsing (BeautifulSoup)
 - JSON 정보 추출 1
 - JSON 정보 확인 (JSON Object)



- 데이터 파싱

```
import requests

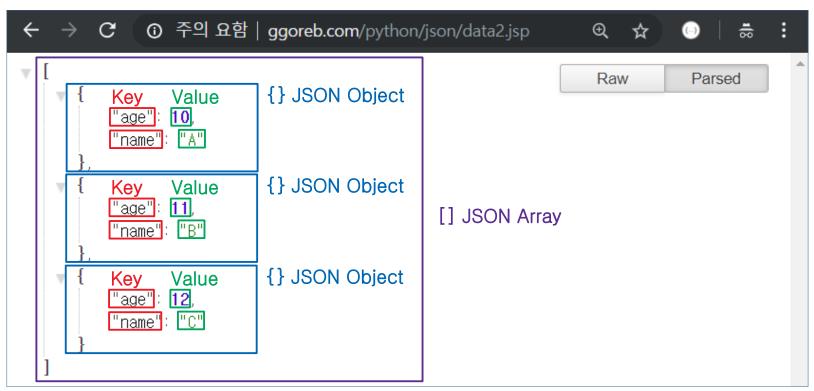
result = requests.get('http://ggoreb.com/python/json/data1.jsp')

parse = result.json() # JSON => Dictionary

print(type(parse))
print(parse['age'])
print(parse['name'])

<class 'dict'>
10
GGoReb
```

- Parsing (BeautifulSoup)
 - JSON 정보 추출 2
 - JSON 정보 확인 (JSON Array)



- Parsing (BeautifulSoup)
 - JSON 정보 추출 2
 - 데이터 파싱

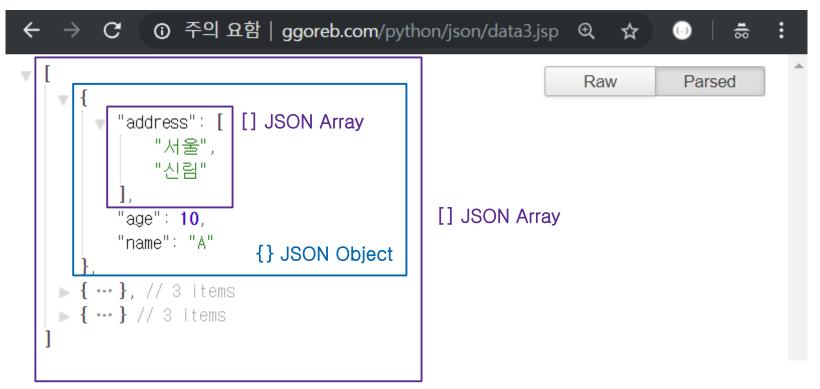
12 C

```
import requests
result = requests.get('http://ggoreb.com/python/json/data2.jsp')
parse = result.json() # JSON => List

print(type(parse))
for data in parse:
    age = data.get('age')
    name = data.get('name')
    print(age, name)

<class 'list'>
10 A
11 B
```

- Parsing (BeautifulSoup)
 - JSON 정보 추출 3
 - JSON 정보 확인 (JSON Array)



- JSON 정보 추출 3
 - 데이터 파싱

```
import requests

result = requests.get('http://ggoreb.com/python/json/data3.jsp')

parse = result.json()

for data in parse:
    address = data.get('address')
    separator = ''
    for add in address:
        print(separator + add, end='')
        separator = ', '
    print()
    age = data.get('age')
    print(age)
    name = data.get('name')
    print(name)
```

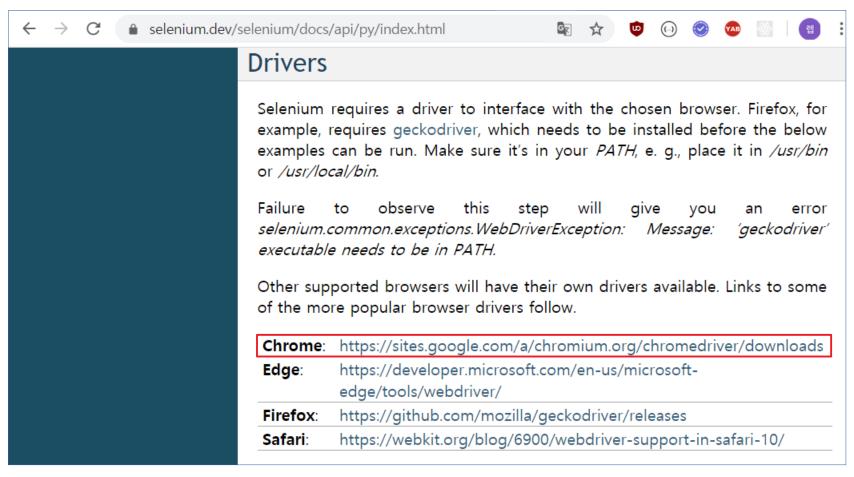
```
서울, 신림
10
A
대전, 탄방
11
B
부산, 해운대
12
C
```

Selenium

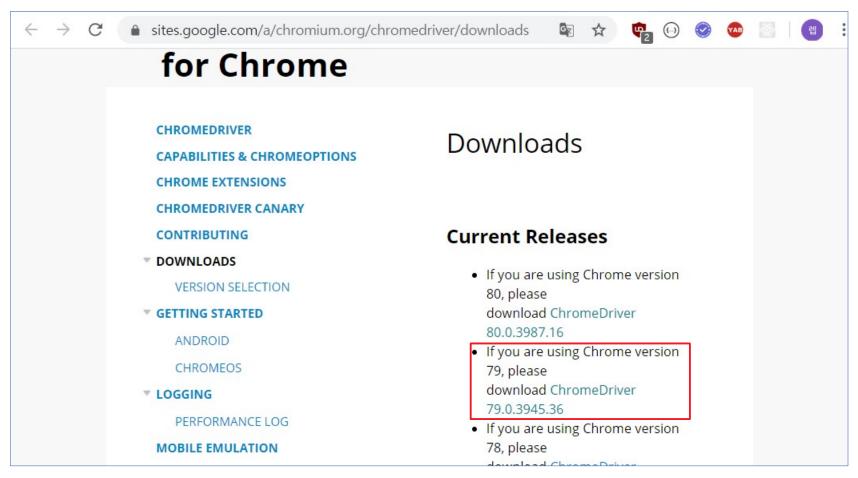
- 브라우저 자동화 라이브러리
- 브라우저를 제어 할 수 있는 웹 드라이버를 통해 매크로와 같은 기능 사용
- 지원 브라우저 : Chrome, Fire Fox, Edge, Safari 등
- 지원 언어: Python, Java, C#, JavaScript 등
- 반드시 사용해야 하는 경우
 - 자바스크립트를 통해 웹 페이지의 내용을 동적으로 생성하는 사이트
 - 프로그래밍 언어의 코드를 이용한 접속이 아닌 실제 브라우저를 통해서만 접속을 허용하는 사이트
 - ex) 네이버 뿜: http://m.bboom.naver.com

리니지M 공지사항: https://lineagem.plaync.com/board/notice/list

- Selenium Web Driver 설치
 - Selenium 공식 사이트
 - https://selenium.dev/selenium/docs/api/py/index.html

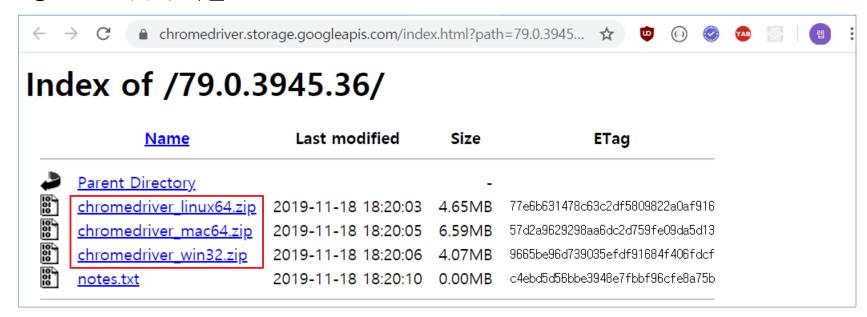


- Selenium 설치
 - Web Driver 다운로드 사이트
 - https://sites.google.com/a/chromium.org/chromedriver/downloads

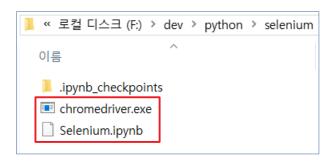


■ Selenium 설치

● Web Driver 다운로드



- 코드를 작성중인 경로로 복사



- Selenium 설치
 - Selenium 다운로드
 - pip install selenium
 - conda install selenium

```
F:\dev\python\selenium>conda install selenium
Collecting package metadata (current repodata.json): done
Solving environment: done
## Package Plan ##
  environment location: C:\Users\GGoReb\Miniconda3
  added / updated specs:
    - selenium
The following NEW packages will be INSTALLED:
  selenium
                     pkgs/main/win-64::selenium-3.141.0-py37he774
522_0
Proceed ([y]/n)?
```

■ Selenium 활용

http://ggoreb.com/http/wait.jsp



- p 태그 확인

```
import requests
from bs4 import BeautifulSoup
result = requests.get('http://ggoreb.com/http/wait.jsp')
soup = BeautifulSoup(result.text, 'html.parser')
print(len(soup.find_all('p'))) # → 0
```

■ Selenium 활용

● 웹 드라이버 로드

from selenium import webdriver as wd driver = wd.Chrome(executable_path='chromedriver.exe')

- 필요시 여러 옵션 사용 가능 (proxy, user-agent, image 생략 등)
- 웹 사이트 접속

 driver.get('http://ggoreb.com/http/wait.jsp')
- 브라우저에 표시된 요소 찾기

print(driver.find_elements_by_tag_name('p'))

[<selenium.webdriver.remote.webelement.WebElement (session="2d31408a49702047badcb96 0b1c7e65f", element="5c052df8-a7c1-4486-b32d-7bb6139a9644")>, <selenium.webdriver.remote.webelement.WebElement (session="2d31408a49702047badcb960b1c7e65f", element="6712a066-80dd-43ee-afcb-0f05a17779ed")>, <selenium.webdriver.remote.webelement.WebElement (session="2d31408a49702047badcb960b1c7e65f", element="58f88c54-6420-44eb-831a-2ba785c74fe4")>]

● 한개 요소 지정 후 내용 확인

print(driver.find_elements_by_tag_name('p')[2].text)

- Selenium 활용
 - 코드가 한꺼번에 실행되는 경우
 - 자바스크립트로 생성되는 요소를 찾는 경우 오류 발생

```
import requests
from bs4 import BeautifulSoup
from selenium import webdriver as wd

driver = wd.Chrome(executable_path='chromedriver.exe')
driver.get('http://ggoreb.com/http/wait.jsp')
print(driver.find_elements_by_tag_name('p'))
print(driver.find_elements_by_tag_name('p')[2].text)
```

wait

- 브라우저에 HTML 요소가 보여진 후 코드 실행
- Explicit Waits (명시적 대기)
 - 지정된 요소가 발견될 때까지 대기
 - 지정된 시간을 초과하는 경우 예외 발생
- Implicit Waits (암시적 대기)
 - 브라우저에 기본 요소(DOM)가 다 로드될 때까지 대기
 - 지정된 시간보다 일찍 로드가 된 경우 먼저 진행
 - 지정된 시간을 초과해도 모든 요소가 로드될 때까지 대기

- wait Explicit(명시적)
 - 웹 드라이버 로드

```
from selenium import webdriver as wd driver = wd.Chrome(executable_path='chromedriver.exe')
```

● 필요 모듈 로드

```
from selenium.webdriver.common.by import By from selenium.webdriver.support.ui import WebDriverWait from selenium.webdriver.support import expected_conditions as EC
```

● 웹 사이트 접속

```
driver.get('http://ggoreb.com/http/wait.jsp')
```

- 브라우저에 표시된 요소 찾기 print(driver.find_elements_by_tag_name('p'))
- 요소가 발견될 때까지 대기 후 찾기

```
try:
    element = WebDriverWait(driver, 10).until(
        EC.presence_of_element_located((By.CSS_SELECTOR, 'p:nth-of-type(2)'))
    )
    print(driver.find_elements_by_tag_name('p')[1].text)
    except Exception as e:
    print('오류 발생', e)
```

■ wait - Implicit(암시적)

● 웹 드라이버 로드

```
from selenium import webdriver as wd driver = wd.Chrome(executable_path='chromedriver.exe')

from selenium.webdriver.common.by import By from selenium.webdriver.support.ui import WebDriverWait from selenium.webdriver.support import expected_conditions as EC driver.get('http://ggoreb.com/http/wait.jsp')

driver.implicitly_wait(10) print(driver.find_elements_by_tag_name('p')[1].text)
```

```
IndexError Traceback (most recent call last)

<ipython-input-11-7f7a5ef18559> in <module>

9

10 driver.implicitly_wait(10)

---> 11 print(driver.find_elements_by_tag_name('p')[1].text)

IndexError: list index out of range
```

■ 요소 제어

http://ggoreb.com/http/control.jsp

```
← → C ① 주의 요함 | ggoreb.com/http/control.jsp
                                         Elements
                                                   Console
                                                          >>
                                                                          \times
검색어 :
버튼
                              •••<!doctype html> == $0
                                <html>
텍스트
                                <head>...</head>
                                ▼ <body>
                                     검색어 : "
                                   <input type="text" placeholder name="search">
                                   <br>
                                   <button type="button" onclick="run()">버튼
                                   </button>
                                   텍스트
                                   <div id="map" data-role="move"></div>
                                   <script>
                                       var run = function() {
                                         alert("버튼 클릭");
                                       };
                                     </script>
                                  </body>
                                </html>
```

- 요소 제어 send_keys() / click()
 - 아이디 / 비밀번호 / 검색어 등 데이터 입력 send_keys()

 driver.find_element_by_tag_name('input').send_keys('검색어 입력')
 - 버튼 등 요소 클릭 click()

 driver.find_element_by_tag_name('button').click()



- 요소 제어 send_keys() / click() / execute_script()
 - 요소의 텍스트 가져오기 text

print(driver.find_element_by_tag_name('p').text)

텍스트

● 요소의 속성 가져오기 - get_attribute()

print(driver.find_element_by_tag_name('div').get_attribute('data-role'))
print(driver.find_element_by_id('map').get_attribute('data-role'))

move move

● 자바스크립트 실행 - execute_script()

driver.execute_script('alert("run script")')

